

综述

人工智能在心功能评估中的应用

蔡雨琪综述, 吴伟春审校

摘要 人工智能的迅速发展, 使其在心血管领域的应用越来越广泛。本文总结了人工智能在心功能评估方面的应用及其进展。机器学习以及深度学习可以自动分析三维超声心动图和 MRI 图像, 识别心室边界快速重建心腔或模拟人眼, 识别心腔的收缩幅度, 评估各心室功能, 全自动分析的心功能参数, 具有实时、可靠、重复性高的特点; 利用超声心动图和心电图等临床的数据构建机器学习模型, 快速评估心室的收缩和舒张功能, 有助于临床医生早期识别心力衰竭患者、预测发生心功能不全的风险、发现疾病的新亚型和心血管疾病的预后。采用人工智能技术可以为临床评估心功能选取最有价值的预测指标, 并推动心血管疾病的诊断和治疗进展

关键词 人工智能; 心功能; 超声心动图; 磁共振成像; 心电图

人工智能是通过模拟人类的学习思维过程, 分析当前大数据时代下繁杂的数据, 提高人类工作效率的一种工具。目前机器学习以及机器学习的子集深度学习是人工智能最常用的子集, 深度学习常用来分析临床原始数据和影像图像等^[1], 机器学习常用于预测、评估心血管疾病的严重程度及预后^[2]。目前, 人工智能在医学上应用普遍, 在心血管方面已逐步涉及。心力衰竭在人群中发病率高, 严重减低患者的生活质量和寿命, 给社会造成了巨大的压力和负担^[3-4]。尤其是射血分数保留的心力衰竭(HFpEF), 占因心力衰竭入院患者的一半以上^[5], 而 HFpEF 没有单一的诊断标准和治疗指南, 预后往往也更差, 准确的评估患者的心功能尤其是舒张功能, 对早期 HFpEF 诊断治疗以及评估预后有重要意义。目前评估心功能的手段较多, 但评估效能不一, 人为测量差异大, 评估的指标繁多, 临床医师无法对每一位患者进行全面的心功能评估, 人工智能以其特有的优势, 被逐步应用于心功能评估中, 有望辅助临床医生高效诊断治疗心功能不全患者, 引领心血管诊疗走向更加精准、个体化的方向^[6]。现对人工智能在心功能评估中的应用进展做一综述。

1 人工智能在心血管疾病领域的发展概况

人工智能最开始被认为是制造智能机器的科学, 现在, 人工智能更多的利用算法, 赋予机器智能推理和执行功能的能力, 并随着科技进步, 逐步转化到各个学科。机器学习和深度学习是人工智能的子集, 被广泛应用于医学领域。机器学习是机器

自动学习参数的过程, 可分为监督学习、无监督学习、半监督学习。监督学习主要是对数据集进行标记, 进行回归分析和预测, 非监督学习对数据集进行降维和聚类, 发现样本之间的关系^[7]。而深度学习属于机器学习的一个子集, 但深度学习的复杂程度和智能水平高于机器学习本身, 深度学习通过模拟人脑的神经系统, 形成卷积神经网络模型或递归神经网络模型等, 自动对数据集的联系进行分析^[8]。在建立人工智能模型的过程中, 数据集被划分为训练集、验证集和测试集。训练集通常包含大量可用数据, 并与较小的验证集一起, 用于模型的开发, 测试集用于评估模型的适用性^[9]。

人工智能在心血管疾病的多个领域广泛应用, 包括对瓣膜病的严重程度评估和预后预测^[10]。深度学习算法在预测肺动脉高压患者的预后和未来事件方面明显优于临床医生^[11]。此外, 人工智能在识别心律失常中亦发挥了重要作用, 利用深度学习模型开发人工智能心电图仪以及智能手表, 可以自动识别心房颤动等心律失常, 监测个体的心电数据情况, 为心律失常的诊疗带来巨大变化^[12]。

2 人工智能在心功能评估的应用

心脏功能常常运用超声心动图、MRI 等影像学手段进行评估, 超声心动图包括二维超声心动图、三维超声心动图、M 型超声心动图等, 具有便携、实用、价格低廉、无放射性等优点, 可用于评估心脏的结构和功能, 但超声心动图结果的准确性依赖于操作者水平, 图像质量水平不一。而 MRI 具有高

作者单位: 100037 北京市, 中国医学科学院 北京协和医学院 国家心血管病中心 阜外医院 超声影像中心

通信作者: 吴伟春 Email: achunductor@163.com

中图分类号: R54 文献标识码: A 文章编号: 1000-3614 (2021) 11-1140-05 DOI: 10.3969/j.issn.1000-3614.2021.11.015

组织分辨率和空间分辨率,成像效果好、重复性好等优点,但 MRI 检查价格高昂、检查周期长,不能被广泛应用于常规的心脏检查中^[13]。利钠肽的水平对评估心功能也有重要意义^[14],但利钠肽的水平受到性别、年龄等因素的影响,部分心功能减低患者利钠肽水平仍保持在正常浓度^[15]。心功能不全常常是其他心血管疾病的晚期并发症,许多患者早期不表现出任何临床症状,常常进展到晚期才出现临床症状,生存质量和寿命明显减低。梅奥中心指出现有的指南指导下心功能不全的治疗效果并不理想,有必要重新定义心力衰竭的诊断标准和治疗策略^[16],应用人工智能分析临床相关数据,有助于早期发现心功能不全患者,发现疾病的新的表型分类,为当前诊断标准提供更好更精确的策略,为心血管诊疗带来更多进步和机会。

2.1 人工智能在左心室收缩功能中的应用

超声心动图是定量评估左心室功能的常用手段,其中左心室射血分数(LVEF)是评估左心室收缩功能最常用的指标,对如急性冠状动脉综合征、急性心肌炎、心力衰竭的预后具有预测意义,此外,LVEF 值对临床心力衰竭的分类有重要意义。二维超声心动图获取射血分数的方式包括:M 型超声心动图法和辛普森双平面法。这两种方法因为受到肌小梁等的干扰以及选取的切面视图短缩导致获得的射血分数值不准确,Asch 等^[17]利用 5 万份来自超声心动图数据库的图像,构建深度学习模型,模拟人眼的直接评估 LVEF,将构建的模型对 99 例患者进行检测,自动获取射血分数值,其结果与 3 名专家使用上述的两种传统方式获得的射血分数值进行比较,两种方式的一致性高: $r=0.94$,偏倚 $=1.4\%$,一致性限度 $=\pm 13.4\%$,敏感度 93%,特异度 87%,表明模型自动获得的射血分数值和专家组人工获取的射血分数值可信度相当。三维超声心动图不需要对心脏进行几何假设,避免因视图短缩而导致心室容积被低估,机器学习模型可以自动识别心内膜和心外膜,识别心脏周期的舒张末期和收缩末期,构建 3D 的左心室腔模型和容积^[17-19],从而获得 LVEF,获取的结果重复性强,与全手工后处理的结果相比,可信度高 r 值达到 0.88,如果医生认为机器识别的边界需要调整,可以手动对心内膜和心外膜边缘进行编辑,编辑后获取的 LVEF 等参数的准确性明显提高,其 r 值增加到 0.94^[19]。同时,检测左心室功能的同时,三维超声心动图可自动分析左心房,获取左心房容积,为临床医生评估心功能提

供更全面的数据^[19]。

人工智能利用分类以及回归算法,可学习病例中的客观的临床特征数据与左心室收缩功能之间的联系,构建机器学习模型,对患者的左心收缩功能进行评估^[15, 20-21]。在一项对因呼吸困难而入急诊的患者回顾性研究中,Attia 等^[20, 22]获取 1 606 例患者的心电图数据,利用 Tensorflow(谷歌张量流图,一种学习系统)+Keras 深度学习库训练的卷积神经网络,对训练集内的所有患者的 12 导联心电图进行学习,在训练过程中,输入由 12×5000 个矩阵组成的十二导联心电图,神经网络使用卷积层对每张图片进行特征提取,通过一层全连接层使用 softmax 激活并实现对心电图的分类,将该分类结果与实际的分类进行比较,最后进行 adam 算法,对网络参数进行优化,获取相应的神经网络模型,构建的神经网络模型自动评估受试者的 LVEF 值,识别 LVEF $<35\%$ 的患者准确度、特异度、敏感度、AUC 分别为 86.5%、86.8%、82.5%、0.918^[16],使用心电图以及其他临床特征可以有效识别射血分数减低的急诊患者,而且模型预测 LVEF 的效能高于利钠肽的预测效能^[15, 20],这是因为利钠肽的浓度受到年龄、性别的影响,神经网络可以克服这一缺陷,对多个临床特征进行自动分析,更准确的识别 LVEF $<35\%$ 的人群,此外神经网络能自动分类识别出有左心室功能减低趋势的患者,这些患者未来 5 年出现左心室收缩功能障碍的风险较正常人群增加了 4 倍^[22]。机器学习中的无监督学习可对数据集内部的相似性进行学习聚类,可以利用心电图数据对收缩功能障碍的患者进行自动聚类^[22],利用基层医院可行的心电图等检查手段早期筛查出收缩功能障碍以及有收缩功能减低趋势的患者,并可利用心电图等其他的临床数据对患者的射血分数值实时评估,当发生射血分数显著降低时及时进行干预。

MRI 检查通过对图像进行后处理,专业医师手动描记心室内膜边界,获取左心室收缩末期和舒张末期的容积,评估左心室射血功能,需耗费大量时间,而且不同水平的医师描记的结果可信度也有差异。机器学习和深度学习模型自动对心内膜进行分割、描记心内膜边界^[7, 23],建立稳定的心脏模型,利用分类器如 softmax 等识别心脏时相,准确识别心室舒张末期和收缩末期^[24],获取左心室的容积、质量、心肌室壁厚度和心脏功能^[7, 24],其中压缩感知成像可从小样本数据库快速采集图像,加速对心脏的重建^[25],并行成像以及实时成像加速 MRI 图像

的获取^[24, 26], 联合卷积神经网络技术, 使临床应用 MRI 全自动重建分析心脏功能成为可能。Böttcher 等^[27] 利用机器学习快速获取心室容积-时间曲线, 获取整个心动周期的左心室容积变化数据, 与传统的手动分析手段相比, 准确性差异无统计学意义, 但对每个患者的分析时间从 (43 ± 14) min 显著缩减到 (2.5 ± 0.5) min, 实现了实时 MRI 评估心功能, 实时获取的左心室容积和变化参数具有潜在的临床意义。

2.2 人工智能在左心室舒张功能中的应用

对于 LVEF 降低的心力衰竭患者, 舒张功能指数变化早于收缩功能, 且舒张功能对心力衰竭患者的治疗效果和预后意义更大^[28], 此外, 舒张功能不全的患者在人群中隐匿性强, 可不表现出任何症状, 准确的评估左心室舒张功能, 识别舒张功能降低的患者, 有助于对心力衰竭患者进行早期诊疗和改善预后。超声心动图是评估左心室舒张功能的重要手段^[29], 人工智能采用二尖瓣舒张早期和晚期的峰值速度 E 峰和 A 峰以及 E/A、组织多普勒二尖瓣环舒张早期速度 e' 、三尖瓣反流峰值流速、左心房容积指数、左心室质量等超声心动图参数评估左心室舒张功能^[21, 29], 其中, 舒张早期二尖瓣环速度 e' 是最成熟的用于评估心肌舒张功能的参数之一, 通常在其他超声心动图指标改变之前提示心肌损伤^[30-31], 常常用来训练评估舒张功能的机器学习模型。有学者通过整合体表信号处理心电图、12 导联心电图的数据和临床特征建立评估舒张功能的监督机器学习模型, 预测的准确程度和超声心动图评估的准确程度相当^[21, 31]。在一项从四个北美机构纳入 1 202 名受试者的前瞻性研究中, 利用训练组的心电数据和临床特征构建的机器学习模型, 可以预测受试者超声心动图组织多普勒的 e' 速度, 内部测试集和外部测试集预测值与实际 e' 速度相当^[31]。此外, 左心室的容积变化和整体纵向应变模式也常用于定量评估左心室舒张功能, 深度学习和机器学习通过分析超声心动图图像, 快速预测左心室的容积和整体纵向应变^[19], 预测结果和 MRI 结果具有良好的一致性^[18]。

左心舒张功能减低患者静息状态下可能不表现出任何症状, 但心脏舒张储备功能明显下降, 负荷状态下的心肌不能代偿, 表现为心肌的舒张运动模式异常, 心肌僵硬增加^[32], 指南建议将心脏储备功能作为评估心功能不全的常规检查^[14]。有研究获取受试者的静息时和负荷下的不同时相的左心室长轴间隔壁和后壁心肌运动的模式数据, 用于构建无

监督机器学习模型, 通过降维获取数据中的相似性, 再利用聚类将相似的特征提取出来, 获得了四个表型不同的亚组, 可更准确的帮助临床医生评估患者的心肌舒张功能, 提供更加精准的治疗策略和预后价值^[33]。

3 人工智能与右心室功能

MRI 是评估右心室功能的金标准^[27, 34], 能客观评估心腔的结构和功能, 通过对专家手动分析的 MRI 图像数据进行学习, 构建机器学习模型, 描记右心室心内膜边界^[23], 自动重建心脏模型, 获取右心室心肌运动模式, 能精确的识别出肺动脉高压患者不良事件发生的概率, 精确度高于右心室射血分数以及右心室应变^[7]。MRI 是评估右心室射血分数和容积的金标准, 但目前 MRI 检查成本高, 检查周期长, 三维经食道超声心动图比 MRI 检查更易获取和操作, 有软件公司开发的机器学习模型对 3D-TEE 图像进行自动分析, 获取右心室的容积和射血分数值, 其中三分之一的患者可以完全自动化分析, 时间仅需 (15 ± 1) s, 而剩下的三分之二的患者需要经过 2 min 左右的手动描边后获取右心室功能。所有的病例的结果具有良好的重现性, 准确度和 MRI 评估结果一致^[35]。Liu 等^[36] 使用基于人工智能算法的分析软件对术中三维经食道超声心动图的右心室图像进行全自动分析, 评估右心室功能相关参数之间的关系, 发现右心室面积变化分数和右心室长轴应变之间有很强的相关性, 且获取的参数的高重复性, 因此可利用人工智能软件, 对患者的应变参数进行分析, 进一步研究应变值与术前危险分层以及术后预后的关系。

三维经食道超声心动图能精确评估右心室功能, 但操作困难, 有创, 二维经胸超声相对三维超声更易获取, 更安全。二维超声获取参数如右心室收缩压、肺动脉舒张压、三尖瓣环收缩期位移、右心室面积变化分数、三尖瓣环收缩峰值速率 S' 速度被用来评估右心室的功能, 利用机器学习分析发现三尖瓣环收缩期位移和 S' 预测评估右心室功能降低的精确度最高^[37]。一项利用机器学习模型预测安装左心室辅助装置患者发生右心衰竭的研究提出, 在所有右心室功能相关参数中, Michigan risk score (用于评估安装左心室辅助装置的患者发生右心室心力衰竭风险的风险评分手段^[38])、中心静脉压、右心室尖端游离壁的收缩期长轴应变对预测急性右心衰竭的准确性最高, 右心室中段游离壁的收缩期应变、三尖瓣环收缩期位移、右心房应变在预测患者

发生慢性右心衰竭的准确性最高,为预测左心室辅助装置植入术后右心衰竭提供更敏感的参数,协助临床医生快速处理并发症^[39]。

4 结论与展望

人工智能能通过学习客观的临床特征如心电图等评估预测患者的心功能,在心血管疾病的临床应用中有巨大潜力,利用现有自动分析软件,分析超声心动图和 MRI 的图像,快速描记心内膜边界,获取心室的大小、容积、质量、功能、运动模式等。通过对大样本的临床数据进行学习和分析,可以识别心功能减低的人群、发现疾病的新的亚型、构建新的有特征性的心功能不全表型分类、判断患者的预后或者发生心功能不全的风险,辅助临床医生对患者进行个性化精确治疗。然而,当前人工智能仍有其局限性,如机器学习模型评估心功能时大多数是对超声心动图获取的数据进行标记构建机器学习模型,而获得的超声心动图质量并不完全一致,低质量的数据不能准确的预测患者的心脏功能。此外,大多数研究受试者样本量集中于某一地区,这样获得的机器学习模型在该地区的预测效果好,但对其他地区人群的评估结果较差,模型不具有普适性。大多数分类模型是对样本进行的回顾性分析,未对受试者的预后进行追踪,而通过聚类分析,获得的特点相似分组的治疗效果和预后对疾病的危险分层和治疗有重要意义,尤其是对 HEpEF 患者尤其重要。在图像识别方面,人工智能的识别准确性很大程度依赖于图像的质量。此外,当前的人工智能模型如同一个“黑箱”,人们即使能理解算法的数学原理,也很难理解这些算法是如何做出决定的,人工智能无法解释黑箱内部的结构和相互之间的因果关系^[40]。

人工智能可以有效地帮助人类拓宽认知的边界,但人类的理性的敏锐的思维是人工智能无法替代的,不可否认,人工智能为心功能的评估提供了巨大的机会,它正在改变诊疗的格局,为临床医生提供有力的辅助工具,提高患者的生活质量和生存时间。不久的将来,人工智能的快速发展将会带领我们进入心血管诊疗的新时代。

利益冲突:所有作者均声明不存在利益冲突

参考文献

- [1] Schuurings MJ, Išgum I, Cosyns B, et al. Routine echocardiography and artificial intelligence solutions[J]. Front Cardiovasc Med, 2021, 8: 648877. DOI: 10.3389/fcvm.2021.648877.
- [2] Steeds RP, Garbi M, Cardim N, et al. EACVI appropriateness criteria for the use of transthoracic echocardiography in adults: a report of literature and current practice review[J]. Eur Heart J Cardiovasc Imaging, 2017, 18(11): 1191-1204. DOI: 10.1093/ehjci/jew333.
- [3] 中国心血管健康与疾病报告编写组. 中国心血管健康与疾病报告 2019 概要 [J]. 中国循环杂志, 2020, 35(9): 833-854. DOI: 10.3969/j.issn.1000-3614.2020.09.001.
- [4] Kurmani S, Squire I. Acute heart failure: definition, classification and epidemiology[J]. Curr Heart Fail Rep, 2017, 14(5): 385-392. DOI: 10.1007/s11897-017-0351-y.
- [5] Lekavich CL, Barksdale DJ, Neelon V, et al. Heart failure preserved ejection fraction (HFpEF): an integrated and strategic review[J]. Heart Fail Rev, 2015, 20(6): 643-653. DOI: 10.1007/s10741-015-9506-7.
- [6] Johnson KW, Shameer K, Glicksberg BS, et al. Enabling precision cardiology through multiscale biology and systems medicine[J]. JACC Basic Transl Sci, 2017, 2(3): 311-327. DOI: 10.1016/j.jacbs.2016.11.010.
- [7] Leiner T, Rueckert D, Suinesiaputra A, et al. Machine learning in cardiovascular magnetic resonance: basic concepts and applications[J]. J Cardiovasc Magn Reson, 2019, 21(1): 61. DOI: 10.1186/s12968-019-0575-y.
- [8] 宋绮蕊, 蔡军. 人工智能及机器学习在心血管疾病中的应用 [J]. 基础医学与临床, 2020, 40(5): 707-710. DOI: 10.16352/j.issn.1001-6352.2020.05.024.
- [9] Al'aref SJ, Anchouche K, Singh G, et al. Clinical applications of machine learning in cardiovascular disease and its relevance to cardiac imaging[J]. Eur Heart J, 2019, 40(24): 1975-1986. DOI: 10.1093/eurheartj/ehy404.
- [10] Zoghbi WA, Adams D, Bonow RO, et al. Recommendations for noninvasive evaluation of native valvular regurgitation: a report from the american society of echocardiography developed in collaboration with the society for cardiovascular magnetic resonance[J]. J Am Soc Echocardiogr, 2017, 30(4): 303-371. DOI: 10.1016/j.echo.2017.01.007.
- [11] Dawes TJW, De Marvao A, Shi W, et al. Machine learning of three-dimensional right ventricular motion enables outcome prediction in pulmonary hypertension: a cardiac MR imaging study[J]. Radiology, 2017, 283(2): 381-390. DOI: 10.1148/radiol.2016161315.
- [12] Tison GH, Sanchez JM, Ballinger B, et al. Passive detection of atrial fibrillation using a commercially available smartwatch[J]. JAMA Cardiol, 2018, 3(5): 409-416. DOI: 10.1001/jamacardio.2018.0136.
- [13] Mavrogeni SI, Sfrikakis PP, Koutsogeorgopoulou L, et al. Cardiac tissue characterization and imaging in autoimmune rheumatic diseases[J]. JACC Cardiovasc Imaging, 2017, 10(11): 1387-1396. DOI: 10.1016/j.jcmg.2017.08.017.
- [14] Pieske B, Tschöpe C, De Boer RA, et al. How to diagnose heart failure with preserved ejection fraction: the HFA-PEFF diagnostic algorithm: a consensus recommendation from the Heart Failure Association (HFA) of the European Society of Cardiology (ESC) [J]. Eur Heart J, 2019, 40(40): 3297-3317. DOI: 10.1093/eurheartj/ehz641.
- [15] Adedinsawo D, Carter RE, Attia Z, et al. Artificial intelligence-enabled ECG algorithm to identify patients with left ventricular systolic dysfunction presenting to the emergency department with dyspnea[J]. Circ Arrhythm Electrophysiol, 2020, 13(8): e008437. DOI: 10.1161/circep.120.008437.

- [16] Oh JK, Miranda WR, Bird JG, et al. The 2016 diastolic function guideline: is it already time to revisit or revise them?[J]. JACC Cardiovasc Imaging, 2020, 13(1 Pt 2): 327-335. DOI: 10.1016/j.jcmg.2019.12.004.
- [17] Asch FM, Poilvert N, Abraham T, et al. Automated echocardiographic quantification of left ventricular ejection fraction without volume measurements using a machine learning algorithm mimicking a human expert[J]. Circ Cardiovasc Imaging, 2019, 12(9): e009303. DOI: 10.1161/circimaging.119.009303.
- [18] Tsang W, Salgo IS, Medvedofsky D, et al. Transthoracic 3D echocardiographic left heart chamber quantification using an automated adaptive analytics algorithm[J]. JACC Cardiovasc Imaging, 2016, 9(7): 769-782. DOI: 10.1016/j.jcmg.2015.12.020.
- [19] Medvedofsky D, Mor-Avi V, Amzulescu M, et al. Three-dimensional echocardiographic quantification of the left-heart chambers using an automated adaptive analytics algorithm: multicentre validation study[J]. Eur Heart J Cardiovasc Imaging, 2018, 19(1): 47-58. DOI: 10.1093/ehjci/jew328.
- [20] Attia ZI, Kapa S, Yao X, et al. Prospective validation of a deep learning electrocardiogram algorithm for the detection of left ventricular systolic dysfunction[J]. J Cardiovasc Electrophysiol, 2019, 30(5): 668-674. DOI: 10.1111/jce.13889.
- [21] Sabovčik F, Cauwenberghs N, Kouznetsov D, et al. Applying machine learning to detect early stages of cardiac remodelling and dysfunction[J]. Eur Heart J Cardiovasc Imaging, 2020, Jun 26: jeaa135. DOI: 10.1093/ehjci/jeaa135.
- [22] Attia ZI, Kapa S, Lopez-Jimenez F, et al. Screening for cardiac contractile dysfunction using an artificial intelligence-enabled electrocardiogram[J]. Nat Med, 2019, 25(1): 70-74. DOI: 10.1038/s41591-018-0240-2.
- [23] Winther HB, Hundt C, Schmidt B, et al. v-net: Deep learning for generalized biventricular mass and function parameters using multicenter cardiac MRI data[J]. JACC Cardiovasc Imaging, 2018, 11(7): 1036-1038. DOI: 10.1016/j.jcmg.2017.11.013.
- [24] Xue W, Brahm G, Pandey S, et al. Full left ventricle quantification via deep multitask relationships learning[J]. Med Image Anal, 2018, 43: 54-65. DOI: 10.1016/j.media.2017.09.005.
- [25] Bustin A, Fuin N, Botnar R M, et al. From compressed-sensing to artificial intelligence-based cardiac MRI reconstruction[J]. Front Cardiovasc Med, 2020, 7: 17. DOI: 10.3389/fcvm.2020.00017.
- [26] Chen X, Yang Y, Cai X, et al. Accelerated two-dimensional cine DENSE cardiovascular magnetic resonance using compressed sensing and parallel imaging[J]. J Cardiovasc Magn Reson, 2016, 18(1): 38. DOI: 10.1186/s12968-016-0253-2.
- [27] Böttcher B, Beller E, Busse A, et al. Fully automated quantification of left ventricular volumes and function in cardiac MRI: clinical evaluation of a deep learning-based algorithm[J]. Int J Cardiovasc Imaging, 2020, 36(11): 2239-2247. DOI: 10.1007/s10554-020-01935-0.
- [28] Aljaroudi WA, Thomas JD, Rodriguez LL, et al. Prognostic value of diastolic dysfunction: state of the art review[J]. Cardiol Rev, 2014, 22(2): 79-90. DOI: 10.1097/CRD.0b013e31829cf733.
- [29] Naguch SF, Smiseth OA, Appleton CP, et al. Recommendations for the evaluation of left ventricular diastolic function by echocardiography: an update from the American Society of Echocardiography and the European Association of Cardiovascular Imaging[J]. Eur Heart J Cardiovasc Imaging, 2016, 17(12): 1321-1360. DOI: 10.1093/ehjci/jew082.
- [30] Kass DA, Bronzwaer JG, Paulus WJ. What mechanisms underlie diastolic dysfunction in heart failure?[J]. Circ Res, 2004, 94(12): 1533-1542. DOI: 10.1161/01.RES.0000129254.25507.d6.
- [31] Kagiya N, Piccirilli M, Yanamala N, et al. Machine learning assessment of left ventricular diastolic function based on electrocardiographic features[J]. J Am Coll Cardiol, 2020, 76(8): 930-941. DOI: 10.1016/j.jacc.2020.06.061.
- [32] Borlaug BA, Paulus WJ. Heart failure with preserved ejection fraction: pathophysiology, diagnosis, and treatment[J]. Eur Heart J, 2011, 32(6): 670-679. DOI: 10.1093/eurheartj/ehq426.
- [33] Sanchez-Martinez S, Duchateau N, Erdei T, et al. Machine learning analysis of left ventricular function to characterize heart failure with preserved ejection fraction[J]. Circ Cardiovasc Imaging, 2018, 11(4): e007138. DOI: 10.1161/circimaging.117.007138.
- [34] Backhaus SJ, Staab W, Steinmetz M, et al. Fully automated quantification of biventricular volumes and function in cardiovascular magnetic resonance: applicability to clinical routine settings[J]. J Cardiovasc Magn Reson, 2019, 21(1): 24. DOI: 10.1186/s12968-019-0532-9.
- [35] Genovese D, Rashedi N, Weinert L, et al. Machine learning-based three-dimensional echocardiographic quantification of right ventricular size and function: validation against cardiac magnetic resonance[J]. J Am Soc Echocardiogr, 2019, 32(8): 969-977. DOI: 10.1016/j.echo.2019.04.001.
- [36] Liu S, Bose R, Ahmed A, et al. Artificial intelligence-based assessment of indices of right ventricular function[J]. J Cardiothorac Vasc Anesth, 2020, 34(10): 2698-2702. DOI: 10.1053/j.jvca.2020.01.024.
- [37] Ahmad A, Ibrahim Z, Sakr G, et al. A comparison of artificial intelligence-based algorithms for the identification of patients with depressed right ventricular function from 2-dimensional echocardiography parameters and clinical features[J]. Cardiovasc Diagn Ther, 2020, 10(4): 859-868. DOI: 10.21037/cdt-20-471.
- [38] Matthews JC, Koelling TM, Pagani FD, et al. The right ventricular failure risk score a pre-operative tool for assessing the risk of right ventricular failure in left ventricular assist device candidates[J]. J Am Coll Cardiol, 2008, 51(22): 2163-2172. DOI: 10.1016/j.jacc.2008.03.009.
- [39] Bellavia D, Iacovoni A, Agnese V, et al. Usefulness of regional right ventricular and right atrial strain for prediction of early and late right ventricular failure following a left ventricular assist device implant: a machine learning approach[J]. Int J Artif Organs, 2020, 43(5): 297-314. DOI: 10.1177/0391398819884941.
- [40] Holzinger A, Langs G, Denk H, et al. Causability and explainability of artificial intelligence in medicine[J]. Wiley Interdiscip Rev Data Min Knowl Discov, 2019, 9(4): e1312. DOI: 10.1002/widm.1312.

(收稿日期: 2021-05-27)

(编辑: 王宝茹)